
Rozpoznawanie Budynków Kampusu PWr na Podstawie Fragmentów Elewacji

Kacper Mikosiński (280985)
Oleksandr Nedosiek (275978)

Wstęp. Zdefiniowanie problemu



Złożoność kampusu: Duża gęstość i różnorodność stylów architektonicznych PWr utrudniają szybką orientację przestrzenną gościom i studentom.



Ograniczenia GPS: Tradycyjna nawigacja satelitarna i mapy topograficzne są niedokładne w pobliżu wysokich fasad akademickich.



Cel projektu: Automatyczne rozpoznawanie budynków kampusu głównego PWr bezpośrednio na podstawie zdjęć elewacji wykonanych aparatem smartfona.



Założenia początkowe: Budowa autorskiego datasetu, wytrenowanie modelu głębokiego uczenie oraz stworzenie ergonomicznej aplikacji mobilnej.

Architektura Wersji 1.0

Akwizycja klatek

Flutter Live Scanner pobiera klatki z kamery, kompresuje i optymalizuje je asynchronicznie w locie.

Preprocessing

Resize/CenterCrop do 256x256, konwersja do tensora PyTorch i normalizacja kanałów barwnych.

Wysyłka HTTP

Transmisja pakietu multipart/form-data POST do serwera FastAPI wykrytego automatycznie przez UDP.


Inferencja AI

Model CNN wyznacza logity. Próg Softmax 60% odrzuca szum i zwraca obiekt JSON z wydziałem.

Praktyka - serwer

```
(venv) PS D:\DANE\studia\sem6\RIP0\ripo_proj1\RiP0\src> py .\server.py
UDP server started on IP: 192.168.0.109:9000
Starting server PWr Scanner...
INFO:      Started server process [29332]
INFO:      Waiting for application startup.
INFO:      Application startup complete.
INFO:      Uvicorn running on http://0.0.0.0:8000 (Press CTRL+C to quit)
INFO:      192.168.0.119:55680 - "POST /predict HTTP/1.1" 200 OK
INFO:      192.168.0.119:51070 - "POST /predict HTTP/1.1" 200 OK
INFO:      192.168.0.119:51076 - "POST /predict HTTP/1.1" 200 OK
INFO:      192.168.0.119:45652 - "POST /predict HTTP/1.1" 200 OK
INFO:      192.168.0.119:45662 - "POST /predict HTTP/1.1" 200 OK
Zapisano błędne zdjęcie: scaled_1000026940.jpg
```

Praktyka - aplikacja



Metodyka i Metryki Walidacji

DOKŁADNOŚĆ OGÓLNA (ACCURACY)

$$\text{Accuracy} = (TP+TN)/(TP+TN+FP+FN)$$

PRECYZJA & CZUŁOŚĆ (PRECISION / RECALL)

$$\text{Precision} = TP/(TP+FP)$$

$$\text{Recall} = TP/(TP+FN)$$

WYNIK F1 (F1-SCORE)

$$\text{F1-score} = 2 * (\text{Precision} * \text{Recall}) / (\text{Precision} + \text{Recall})$$


Środowisko Badawcze

- Zbiór testowy: 1000 odizolowanych, zbalansowanych fotografii (po 100 dla każdej z 10 klas).
- Brak IoU: Zgodnie ze specyfikacją systemu 1.0, miara IoU została wyeliminowana, gdyż model klasyfikuje cały obraz zamiast rysować ramki (bounding boxes).
- Wyznaczenie FPS: Mierzone jako suma czasu akwizycji/kompresji, transmisji sieciowej HTTP oraz inferencji GPU CUDA.

Wyniki Ewaluacji na Zbiorze Testowym

Klasa (Budynek PWr)	Precyzja (Precision)	Czułość (Recall)	Wynik F1 (F1-Score)	Wsparcie
D-20	0.86	0.83	0.85	100
C-13 ("Serowiec")	0.75	0.79	0.77	100
C-3/4	0.71	0.74	0.73	100
A-1	0.72	0.69	0.70	100
C-18 (Podobny do C-16)	0.82	0.41	0.55	100
C-16	0.49	0.75	0.59	100
C-1	0.53	0.83	0.64	100
C-7	0.85	0.63	0.72	100
D-1	0.82	0.66	0.73	100
H-6	0.69	0.57	0.62	100
Macro Avg	0.72	0.69	0.69	1000
Globalne Accuracy	69.0% (690 / 1000)	1000		

Analiza Czułości Modelu i Pomyłek



Główny punkt pomyłek: niska czułość dla C-18 - model pomylił go z C-16 aż 33 razy. Podobnie dla H-6: mylił się on z C-3/4 22 razy.

Trudne Scenariusze i Przyczyny

PRZYCZYNY I WĄSKIE GARDŁA

 **Utrata kontekstu skali:** Agresywne kadrowanie ``RandomResizedCrop`` dostarczało ciasne wycinki elewacji, przez co sieć gubiła globalną bryłę budynków.

 **Dystorsja, Szum, Mory:** Wyświetlanie wirtualnych spacerów 3D na monitorze wprowadzało zniekształcenia, obniżając ufność do poziomu 60-69%.

 **Wrażliwość na Occlusion:** Zasłonięcie centralnej części kadru (np. dłonią do 35%) drastycznie odcinało wagi aktywacji modelu, paraliżując predykcję.

 **Opóźnienie Sieciowe:** Sama inferencja na GPU CUDA trwa poniżej 5-20 ms, ale przesył klatki przez HTTP POST zwiększa latency do 42-115 ms.

Konfrontacja Pierwotnych Założeń

Zaimplementowany system wykazuje przydatność w warunkach rzeczywistych, stanowiąc stabilny prototyp inżynierski o wysokiej selektywności dla budynków o unikalnej architekturze.



Kierunki Rozwoju i Przyszłość



Korelacja z sensorem GPS: Wykorzystanie nawet zgrubnych współrzędnych do dynamicznego nałożenia maski Softmax, co całkowicie wyeliminuje pomyłki podobnych elewacji w odległych częściach kampusu.



Architektura Vision Transformer (ViT): Zastąpienie sieci SimpleModel modelami z mechanizmem uwagi (Self-Attention) w celu skuteczniejszego uczenia relacji przestrzennych gmachów.



Temporal Pooling (Agregacja w czasie): Analiza okna czasowego (średnia z 5 klatek wideo) po stronie klienta mobilnego zapobiegająca "migotaniu" predykcji.



Rozbudowa bazy o warunki skrajne: Dołączenie ujęć nocnych, zimowych (brak liści przysłaniających fasadę) oraz silnych fluktuacji nasłonecznienia.

Pytania?

Dziękujemy za uwagę!
